Avril 2026

Détection de fraude par carte bancaire

Projet Machine Learning — Polytech Semestre 4

Jegham Mohamed **Ben Mansour Louay**

Parcours Machine Learning

Plan

1. Contexte et données

2. Méthodologie

3. Résultats

4. Dérive et limites

5. Conclusion

Contexte et données

1

Contexte

Enjeux de la fraude bancaire

Volume élevé de transactions $\rightarrow$ nécessité d'un **scoring automatique** robuste.

- Pertes financières, obligations réglementaires et confiance client en jeu.
- Classification binaire : **légitime** *vs* **frauduleux** sur données tabulaires réelles.
- Benchmark académique standard : dataset ULB / Kaggle.

Jeu de données — ULB / Kaggle

- Fichier `creditcard.csv` : $\approx 285\,000$ transactions.
- Variables : `Time`, `Amount`, `V1`–`V28` (PCA anonymisée), cible `Class` $\in \{0, 1\}$.
- **Déséquilibre sévère** : $< 0.2\,\%$ de fraudes.
- L'exactitude brute est *trompeuse* $\rightarrow$ F1, ROC-AUC, Précision, Rappel.

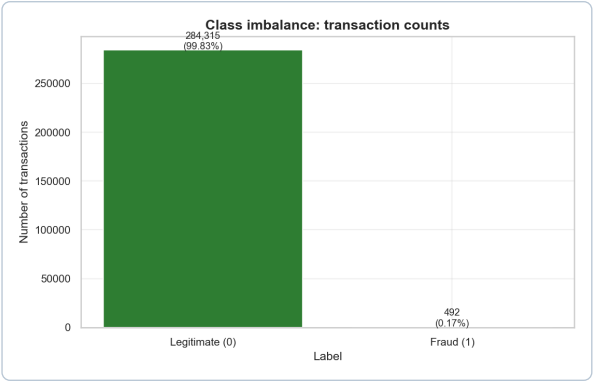

Exploration : corrélations et distributions

Corrélations (heatmap)

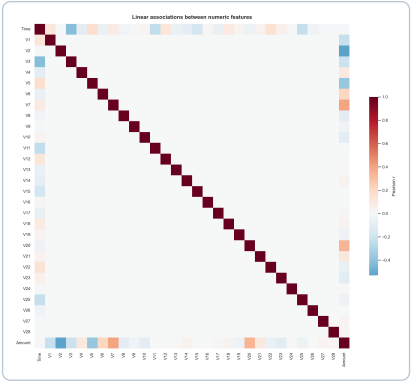

Distributions des features

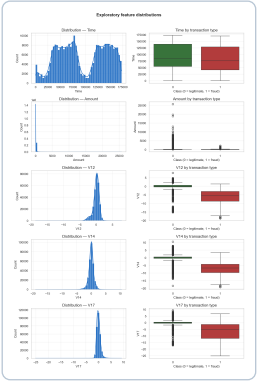

Méthodologie

2

Pipeline de traitement (vue d'ensemble)

1. **EDA** : distributions, corrélations, valeurs manquantes.
2. **Split temporel** : tri par `Time`, train = début, test = fin — plus réaliste.
3. **Features** : `log1p(Amount)`, ratios vs moyenne mobile causale (sans fuite).
4. **Sélection** : régularisation L1 (logistique) sur le train.
5. **Rééquilibrage** : standardisation + **SMOTE** (train uniquement, `imblearn`).
6. **Modèles** : LR, Arbre, RF (GridSearch), XGBoost, LightGBM.
7. **Seuil optimal** : courbe PR + coût métier $C_{\mathrm{FN}} \cdot \mathrm{FN} + C_{\mathrm{FP}} \cdot \mathrm{FP}$.
8. **Post-traitement** : calibration, dérive (KS, PSI), SHAP.

SMOTE : rééquilibrage sur le train

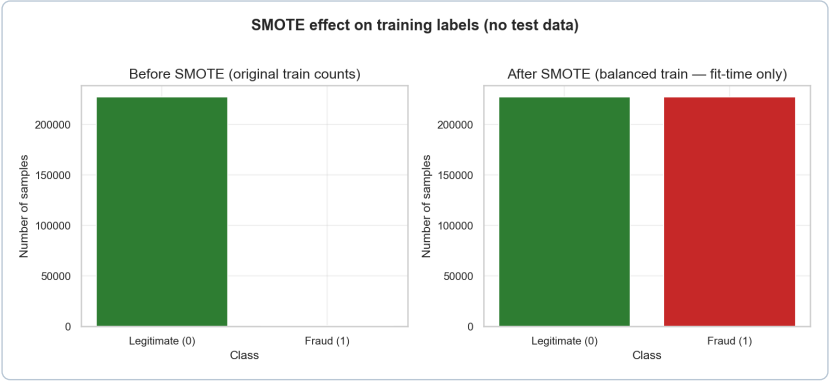

Résultats

3

Comparaison des modèles (jeu de test)

Valeurs indicatives — mettre à jour depuis `model_results.csv`.

Modèle	Acc.	Préc.	Rappel	F1	AUC
Régression logistique	0,974	0,058	0,918	0,109	0,971
Arbre de décision	0,986	0,097	0,827	0,174	0,869
Random Forest (opt.)	**0,999**	**0,804**	**0,796**	**0,800**	**0,978**
XGBoost	0,998	0,452	0,867	0,594	0,976

Ligne verte = modèle retenu. Recopier depuis le CSV pour coller à votre exécution.

Matrice de confusion : modèle retenu

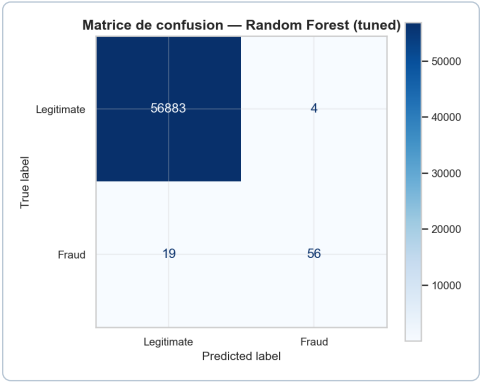

Courbe ROC

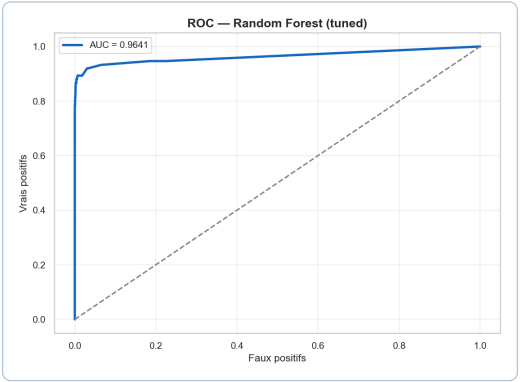
ROC — Random Forest (tuned)
AUC = 0.9641
Vrais positifs
Faux positifs
0.0
0.2
0.4
0.6
0.8
1.0

Précision–Rappel et choix de seuil

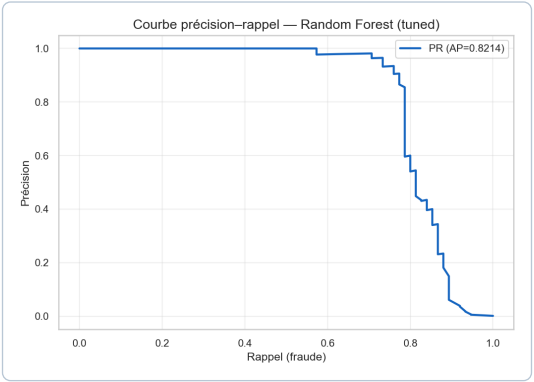

Calibration des probabilités

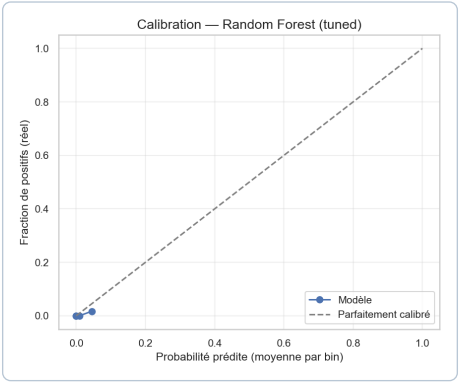

Importance des variables (modèle retenu)

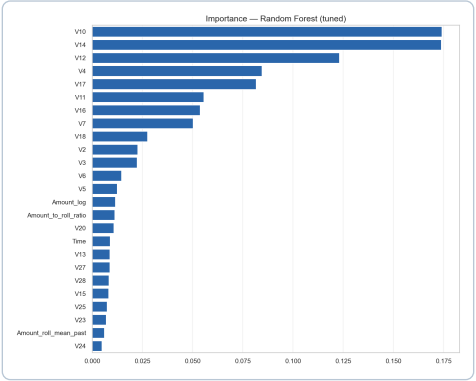

Explicabilité : SHAP (summary plot)

SHAP non généré. Vérifier : pip install shap ; exécuter tout le notebook ;
meilleur modèle = arbre (RF, XGB, LGBM) ou régression logistique.
Voir les messages Python au-dessus.

Dérive et limites

4

Dérive train *vs* test

- Tests **Kolmogorov–Smirnov** et **PSI** sur `Amount` et les `V*` clés.
- Rapport exporté : `drift_report.csv`.
- Cohérent avec le split temporel : les distributions évoluent légèrement en fin de période.

Point de vigilance

Un PSI > 0.20 sur une variable clé signale une dérive significative nécessitant un re-entraînement.

Limites et perspectives

Limites

- Données de 2013 : risque de dérive en production.
- Variables PCA anonymisées : interprétation métier restreinte.

Pistes

- CatBoost, TabNet.
- Coûts métier personnalisés.
- MLOps : monitoring PSI/KS continu.

Conclusion

Conclusion

Pipeline reproductible livré

`requirements.txt` · notebooks `01_EDA` / `02_Modeling` · `src/` · tests `pytest`

- Automatisation : `Makefile`, `tasks.ps1` ; CI GitHub Actions.
- **Random Forest optimisé** : meilleur compromis Précision/Rappel (F1 = 0,80, AUC = 0,978).
- Le modèle est un **outil d'aide à la décision** : seuil et gouvernance restent du ressort métier.

Merci de votre attention

Dataset Kaggle — ULB Credit Card Fraud

Jegham Mohamed Ben Mansour Louay · Parcours Machine Learning